lumo

Riesgo de cierre temprano de restaurantes en Colombia

Reto R10 · Anteproyecto del Proyecto Final Integrador. Fase CRISP-DM: comprensión del negocio.

SANTIAGO SIMANCA (TRABAJO INDIVIDUAL) · MACHINE LEARNING I (IMPN0004) · PROF. JAIME ALBERTO OCHOA DURÁN · UNIVERSIDAD EAN · VERSIÓN 2 · 8 DE OCTUBRE DE 2026

00 Resumen

LUMO es una plataforma, en construcción y aún sin clientes, que permite a un restaurante conversar con sus propios datos para tomar decisiones. Este proyecto construye un modelo de clasificación que estima qué restaurantes nuevos tienen mayor riesgo de cerrar en sus primeros tres años. Como el cierre real no se observa directamente, se mide con su huella en el registro mercantil (cancelar o dejar de renovar la matrícula del establecimiento), con datos reales y abiertos de Confecámaras enriquecidos con otras fuentes públicas. El resultado apoya dos decisiones: a qué restaurantes priorizar y con qué mensaje (uso interno), y un termómetro de riesgo en la web de LUMO para que los propios dueños midan su riesgo (uso público).

01 Problema y decisión

Elemento	Definición
Decisión que apoya	A qué restaurantes nuevos priorizar en la salida al mercado de LUMO, y con qué mensaje.
Quién decide	Santiago Simanca, fundador de LUMO.
A quién afecta	A los dueños de restaurantes nuevos: a quién se le ofrece acompañamiento y a quién no. En el uso público, al dueño que interpreta su propio resultado.
Pregunta del modelo	De los restaurantes nuevos, ¿cuáles tienen mayor riesgo de cerrar antes de cumplir tres años?

Cómo se mide el cierre	Con un proxy observable: el establecimiento cancela su matrícula o deja de renovarla antes de cumplir tres años. Es la misma fuente (el RUES) que usa Confecámaras para sus estudios de supervivencia empresarial.
Por qué esta pregunta	Un restaurante en riesgo es el que más necesita leer sus números a tiempo, que es la promesa de valor de LUMO. Además, el pasado ofrece miles de casos con desenlace conocido, lo que permite aprender de forma supervisada.

Paradigma elegido y por qué

Aprendizaje supervisado, clasificación binaria. Existe una etiqueta histórica observable (cerró o siguió) para cientos de miles de casos. No es regresión porque la decisión es priorizar, no estimar una cantidad. El aprendizaje no supervisado (lecciones 15 a 17) se usará de forma complementaria para describir segmentos de restaurantes, no para predecir.

02 Enfoque elegido: emprendimiento

Se reclama el bono de enfoque de emprendimiento. Primera versión de los cinco elementos que exige la rúbrica:

Elemento del bono	Primera versión
Propuesta de valor	LUMO convierte los datos de un restaurante en decisiones claras, en lenguaje conversacional, antes de que los problemas se vuelvan irreversibles.
Usuario o cliente concreto	Dueños de restaurantes formales, pequeños y nuevos (con matrícula mercantil reciente), empezando por Bogotá.
Hipótesis de negocio	Los dueños de restaurantes con perfil de mayor riesgo valoran más una herramienta que les ayude a leer sus números, y un termómetro de riesgo gratuito es una puerta de entrada eficaz a LUMO.
Estimación del impacto (supuestos declarados)	Mercado de entrada: en 2024 se matricularon 16.523 restaurantes en Colombia (consulta al registro mercantil, 8 de octubre de 2026). Supuesto ilustrativo, por validar: si el 2 % de ellos usara el termómetro en un año (unos 330) y el 10 % de esos se registrara en LUMO, serían unos 33 restaurantes registrados al año solo por este canal. Las tasas del 2 % y el 10 % son supuestos, no datos.
Ruta para validar la hipótesis	1. Entrevistar al menos a 5 dueños de restaurantes nuevos sobre cómo leen sus números y qué los presiona. 2. Probar el mensaje del termómetro con ellos. 3. Medir, ya desplegado, cuántos usuarios del termómetro pasan a registrarse.

> **Pendiente:** la sección "Cómo usé lo aprendido en las microcredenciales", con al menos dos técnicas o herramientas concretas de las microcredenciales EanX y dónde se aplicaron. Se completa cuando terminen las microcredenciales.

03 Datos reales

La base es el registro mercantil. La unidad de análisis es el **establecimiento** (el local del restaurante), que es lo más cercano a "un restaurante que abre y cierra". A esa base se le suman otras fuentes públicas para tener más variables.

Fuente base: establecimientos de restaurante

Campo de la ficha	Valor preliminar
Conjunto	Establecimientos – Agencias – Sucursales (registro mercantil sincronizado con el RUES)
Publicador y dirección	Confecámaras · https://www.datos.gov.co/d/nb3d-v3n7
Licencia	Creative Commons Atribución-CompartirIgual 4.0 Internacional · actualización mensual
Fecha de acceso	8 de octubre de 2026
Subconjunto de trabajo	Establecimientos con actividad principal CIIU 5611 (expendio a la mesa de comidas preparadas): 256.364 filas; 118.427 activos y 136.384 cancelados
Cruce con el dueño	Por la matrícula del propietario, con el conjunto Personas Naturales, Personas Jurídicas y ESAL (https://www.datos.gov.co/d/c82u-588k, CC BY-SA 4.0, actualización mensual): 290.889 registros con CIIU 5611
Datos personales	Incluye nombres e identificaciones de personas naturales. Se usan solo para cruzar y se eliminan antes de analizar (Ley 1581 de 2012)

Variable objetivo

`cierre_3a` = 1 si el establecimiento canceló su matrícula o dejó de renovarla antes de cumplir tres años desde su apertura; 0 si siguió activo y renovando. Ventana de análisis: aperturas entre 2015 y 2022, para que todos los casos tengan tres años completos de observación. Se excluyen cancelaciones por traslado de domicilio o fusión, que no son cierres.

Fuentes públicas para más variables

Ninguna fuente sola describe por qué cierra un restaurante. Estas son las que se pueden combinar, todas públicas y válidas para el bono de datos reales:

Fuente	Qué aporta al modelo	Cómo se cruza	Estado
Establecimientos – Agencias – Sucursales (Confecámaras)	La base: apertura, cancelación, renovación, ciudad, actividades secundarias	Unidad de análisis	VERIFICADA
Personas Naturales, Jurídicas y ESAL (Confecámaras)	Tipo de dueño (persona natural, SAS) y número de locales del mismo dueño	Matrícula del propietario	VERIFICADA

Estados financieros NIIF (Supersociedades, datos.gov.co)	Ingresos, activos, deudas y resultado (CC BY-SA 4.0, anual), solo para sociedades que reportan a Supersociedades	NIT	EXISTE; FALTA MEDIR COBERTURA
Gran Encuesta Integrada de Hogares, informalidad por ciudad (DANE)	Qué tan informal es la ciudad donde abre el restaurante	Ciudad y año	POR DESCARGAR
Índice de precios al consumidor, comidas fuera del hogar (DANE)	Si los precios de comer fuera subían o no cuando abrió	Año (y ciudad si está disponible)	POR VERIFICAR
Proyecciones de población por municipio (DANE)	Tamaño del mercado: restaurantes por cada 10.000 habitantes (competencia)	Ciudad y año	POR DESCARGAR
EMIS y Euromonitor (plataformas del taller del Módulo 2B)	Tamaño y crecimiento del mercado de restaurantes; datos financieros de empresas	Año, ciudad o NIT	SEGÚN ACCESO DEL TALLER
Encuesta de Micronegocios, EMICRON (DANE)	No se cruza fila a fila; sirve para dimensionar la informalidad del sector y describir el límite del modelo	Contexto	SOLO CONTEXTO

Las variables de contexto (ciudad y año) no describen a cada restaurante, pero recogen condiciones que la literatura asocia con la supervivencia, como la competencia y el crecimiento del sector (Domínguez et al., 2017).

Predictores candidatos (solo información conocida el día de la apertura)

Ciudad, tipo de dueño, número de locales del dueño al abrir, actividades secundarias (bar, domicilios), año y mes de apertura, año de pandemia, informalidad de la ciudad, densidad de restaurantes por habitante y, cuando exista, el tamaño financiero de la empresa dueña.

Lo que el modelo no puede ver (límite declarado)

Ventas, ubicación exacta, calidad, deudas de los negocios pequeños y, sobre todo, la informalidad: un restaurante puede cancelar su matrícula y seguir operando de manera informal, o cerrar sin cancelarla. Por eso el modelo estima un riesgo aproximado por perfil, no una probabilidad exacta para un restaurante en particular.

Columnas excluidas por fuga de información

Columna	Motivo
estado_matricula, fecha_cancelacion, ultimo_ano_renovado, fecha_renovacion	Son el desenlace: solo se usan para construir la variable objetivo, nunca como predictores.

Datos financieros posteriores a la apertura	Si se usan estados financieros, solo los del primer año; los siguientes ya cuentan cómo le fue.
fecha_actualizacion, fecha_vigencia	Información posterior a la matrícula.
Nombres, identificaciones, NIT, representante legal	Datos personales sin valor predictivo legítimo.

Regla de diseño: el modelo solo usa lo que se sabía el día en que el restaurante abrió.

04 Métricas: técnica y de negocio

La rúbrica pide separar la métrica técnica de la métrica de éxito del negocio.

Tipo	Métrica	Por qué
Técnica principal	Recall de la clase "cerró"	Dejar sin detectar a un restaurante que sí iba a cerrar cuesta más que contactar a uno que no lo necesitaba.
Técnica complementaria	ROC-AUC y precisión, con validación cruzada estratificada	El ROC-AUC mide si el modelo ordena el riesgo mejor que el azar sin depender del umbral; la precisión controla las falsas alarmas.
Éxito del negocio (interno)	De cada 100 restaurantes marcados como de alto riesgo, cuántos cancelaron de verdad	Dice si priorizar con el modelo es mejor que elegir al azar. Se compara contra la tasa base de cierre.
Éxito del negocio (público)	Porcentaje de usuarios del termómetro que se registran en LUMO	Mide si el despliegue genera clientes. Solo se puede medir después de desplegar.

Las metas numéricas (por ejemplo, un recall mínimo) se fijan en el R12, cuando se conozca la tasa base de cierre en la ventana 2015–2022.

05 Riesgos iniciales

Tipo	Riesgo	Mitigación
Técnico	Fuga de información por columnas de renovación o cancelación	Excluirlas antes de partir los datos; partir antes de transformar; Pipeline.
Técnico	Pocos predictores propios: el registro no trae ventas, empleados ni activos	Enriquecer con las fuentes públicas de la sección 3; aceptar un modelo modesto bien evaluado.
Técnico	Los estados financieros solo cubren a empresas grandes	Medir la cobertura en el R11; si es baja, usarlos en un análisis aparte y no en el modelo principal.

Datos	Cancelar o no renovar no siempre es cerrar (venta, fusión, traslado, paso a la informalidad); y cerrar no siempre se registra	Excluir traslados y fusiones; nombrar la variable como proxy; declarar la informalidad como límite.
Datos	La pandemia de 2020 afectó a los restaurantes abiertos entre 2017 y 2019	Revisar la tasa de cierre por año de matrícula y considerar una validación por periodos.
Representatividad	Solo están los restaurantes formales; el sector informal queda por fuera	Declararlo como límite del modelo y de sus conclusiones.
Ético	Estigmatizar o desalentar a un emprendedor con un "vas a cerrar"	El termómetro muestra niveles (bajo, medio, alto) como "restaurantes con un perfil parecido al tuyo", no un porcentaje personal; ofrece ayuda; prohibido usarlo para negar crédito o arriendo.
Ético	Privacidad de personas naturales	Eliminar nombres e identificaciones al cargar; no publicar datos individuales.
Interpretación	Confundir correlación con causalidad	Presentar los factores como asociaciones, no como causas del cierre.

06 Plan por retos (trazabilidad CRISP-DM)

Reto	Fase	Entregable en el repositorio
R10	Comprensión del negocio	Este anteproyecto.
R11	Comprensión de los datos	Descarga de los establecimientos CIIU 5611 y de las fuentes de enriquecimiento, cruces, ficha de datos y diagnóstico de calidad columna por columna; cobertura de cada fuente.
R12	Preparación	Variable objetivo, partición antes de transformar, Pipeline sin fuga y línea base.
R13	Modelado y evaluación	Comparación de al menos tres familias de modelos con validación cruzada estratificada; umbral recomendado.
R14	Modelado	Informe de avance consolidado.
R15–R17	Modelado y evaluación	Segmentos de restaurantes con aprendizaje no supervisado, si aplica.
R18	Despliegue y cierre	Resumen ejecutivo en inglés, plan de seguimiento y termómetro de riesgo en la web de LUMO.

Entrega del proyecto: jueves 22 de octubre de 2026, 11:59 p. m. Sustentación: sábado 24 de octubre de 2026.

07 Preguntas abiertas para los profesores

1. El registro mercantil trae pocas variables y no captura la informalidad. ¿Es razonable enriquecerlo con fuentes públicas por ciudad y año (DANE) y con estados financieros de Supersociedades aunque cubran pocos restaurantes?
2. ¿El registro mercantil de Confecámaras y las fuentes del DANE cuentan para el bono de datos reales, anonimizando nombres e identificaciones?
3. ¿El enfoque de emprendimiento se sostiene con un producto sin clientes, usando datos de mercado y una ruta de validación con dueños de restaurantes?
4. ¿"Cancelar o dejar de renovar la matrícula" es un proxy aceptable de cierre? ¿Qué estados conviene excluir?
5. ¿Es válido trabajar con una muestra estratificada del total para que todos los modelos corran en Colab?
6. ¿Una sección web con el termómetro de riesgo cumple el bono de despliegue?
7. Si las lecciones 15 a 18 ocurren después del 22 de octubre, ¿qué retos deben estar en el repositorio para la entrega?

08 Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Domínguez Rivera, J., Ramírez Barbosa, C., Murillo Lozano, M., Restrepo Sánchez, L. M., y Guevara, J. S. (2017). *Determinantes de la supervivencia empresarial en Colombia* (Cuadernos de Análisis Económico n.º 14). Confecámaras. https://confecamaras.org.co/wp-content/uploads/2024/01/cuaderno-de-analisis-economico-n-14.pdf

Confecámaras. (2026). *Personas Naturales, Personas Jurídicas y Entidades Sin Ánimo de Lucro* [Conjunto de datos]. Datos Abiertos Colombia. Recuperado el 8 de octubre de 2026, de https://www.datos.gov.co/d/c82u-588k

Confecámaras. (2026). *Establecimientos – Agencias – Sucursales* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/nb3d-v3n7

DANE. (s. f.). *Gran Encuesta Integrada de Hogares: empleo informal y seguridad social*. Departamento Administrativo Nacional de Estadística. https://www.dane.gov.co

Kaufman, S., Rosset, S., Perlich, C., y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data, 6*(4), 1–21. https://doi.org/10.1145/2382577.2382579

Superintendencia de Sociedades. (2026). *Estados financieros NIIF – Estado de resultado integral* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/prwj-nzxa

Ley 1581 de 2012. Por la cual se dictan disposiciones generales para la protección de datos personales. Congreso de la República de Colombia.

Uso de inteligencia artificial: este anteproyecto se preparó con apoyo de Claude (Anthropic) para buscar y verificar la fuente de datos, estructurar el documento y redactar una primera versión. El autor revisa, ajusta y responde por cada decisión. El detalle va en declaracion_IA.md.