lumo · informe de avance

Termómetro de riesgo para restaurantes

Proyecto Final Integrador de Machine Learning I. Qué hemos hecho, qué resultados tenemos, qué falta hasta el 22 de octubre y qué necesitamos preguntarle al profesor.

SANTIAGO SIMANCA Y PEDRO · MACHINE LEARNING I (IMPN0004) · UNIVERSIDAD EAN · 16 DE OCTUBRE DE 2026 · VERSIÓN DE AVANCE PARA FEEDBACK

00 El proyecto en una mirada

> LUMO es un software para restaurantes. Con datos reales del DANE sobre 7.523 negocios de comida entrenamos un modelo que estima si un negocio está en **riesgo financiero**, y lo mostramos como un **termómetro** en la web de LUMO: el dueño responde 10 preguntas y ve su nivel de riesgo y qué le está pesando más.

Criterio de la rúbrica	Estado	Qué tenemos
Comprensión del negocio (12 pts)	AVANZADO	Decisión, usuario, métrica de negocio y paradigma definidos. Falta redactar riesgos éticos completos.
Datos: procedencia, calidad, representatividad (12)	EN CURSO	Datos descargados, unidos y diagnosticados. Falta la ficha de datos final.
Preparación sin fuga (12)	AVANZADO	Partición por hogar antes de transformar, Pipeline, columnas prohibidas listadas.
Modelado con línea base (14)	EN CURSO	Línea base y 4 modelos comparados. Falta ajustar hiperparámetros por validación cruzada.
Evaluación y costo del error (14)	PENDIENTE	Métricas preliminares. Falta umbral, prueba final única y auditoría de equidad.
Decisión, límites y gobernanza (12)	PENDIENTE	Límites identificados. Falta redactar.

Trazabilidad y reproducibilidad (12)	EN CURSO	Semilla fija. Falta repositorio en GitHub y cuaderno final.
Comunicación, inglés y declaración de IA (12)	PENDIENTE	Declaraciones de IA por sesión. Falta informe y resumen en inglés.

01 El cambio más importante: de "cierre" a "riesgo financiero"

El anteproyecto (R10) planteaba predecir qué restaurantes **cierran en 3 años**, con el registro mercantil de Confecámaras (RUES). Al revisar los datos vimos un problema de fondo para el termómetro:

> **Regla que descubrimos:** el termómetro solo puede hacerle al usuario las preguntas que existían como columnas en los datos de entrenamiento. El RUES solo trae ciudad, fecha de matrícula y tipo de dueño: un formulario de tres preguntas. Además, no ve a los negocios informales, que son casi el 90 % de los micronegocios del país.

	Antes · RUES (Confecámaras)	Ahora · EMICRON 2024 (DANE)
Pregunta del modelo	¿El restaurante cierra antes de 3 años?	**¿El negocio le deja al dueño menos de medio salario mínimo al mes?**
Filas	106.859 aperturas 2015–2022	7.523 negocios de comida y alojamiento
Variables útiles	3 o 4	Más de 20 candidatas (tamaño, formalidad, cuentas, lugar, tecnología, crédito)
Informalidad	No la ve	La mide: solo 12,8 % de estos negocios está en Cámara de Comercio
Termómetro	Pobre	Rico y accionable para el dueño
Costo del cambio	—	La pregunta ya no es "cierre", sino "salud financiera". El RUES queda como contexto en el informe (26,6 % cierra antes de 3 años).

02 Problema y decisión

Elemento	Definición
Decisión de negocio	A qué restaurantes ofrecerles LUMO primero y con qué mensaje, según qué tan en riesgo están y qué les está pesando.
Quién decide	Santiago, como fundador de LUMO. El dueño del restaurante usa el termómetro para mirarse a sí mismo.
A quién afecta	Dueños de micronegocios de comida, muchos informales, que trabajan en su vivienda o en la calle.

Variable objetivo	`riesgo = 1` si el negocio le deja al dueño menos de $650.000 al mes, es decir, medio salario mínimo de 2024 (pregunta `P3072`).
Paradigma	Aprendizaje supervisado, clasificación binaria.
Métrica técnica	ROC-AUC (ordenar bien el riesgo) y exhaustividad (no dejar pasar negocios en riesgo), con validación cruzada.
Métrica de negocio	De cada 100 negocios que el termómetro marca como riesgo alto, cuántos lo están de verdad; y cuántos dueños pasan del termómetro a registrarse en LUMO.

¿Por qué medio salario mínimo y no uno entero? Con un salario mínimo completo, el 79 % de los negocios queda "en riesgo" y el termómetro diría "alto" a casi todos. Con medio, el 51 % queda en riesgo: el modelo y el termómetro sí pueden diferenciar.

03 Datos

Ficha resumida	Valor
Fuente	DANE, Encuesta de Micronegocios (EMICRON) 2024, microdatos anonimizados. microdatos.dane.gov.co, catálogo 875.
Fecha de acceso	15 de octubre de 2026
Módulos usados	8 de 12: identificación, características, sitio, personal ocupado (propietario), TIC, inclusión financiera, ventas, costos. Unidos por `DIRECTORIO + SECUENCIA_P + SECUENCIA_ENCUESTA`, sin duplicados.
Filas	78.501 micronegocios en total; **7.523** del grupo "alojamiento y servicios de comida" (`GRUPOS12 = 07`)
Balance de la variable objetivo	51,1 % en riesgo y 48,9 % no
Cita APA 7	Departamento Administrativo Nacional de Estadística [DANE]. (2025). *Encuesta de Micronegocios (EMICRON) 2024* [Conjunto de datos]. https://microdatos.dane.gov.co/index.php/catalog/875

Diagnóstico de calidad: la "suciedad" real que encontramos

Columna	Vacíos	Qué significa y qué haremos
Acepta transferencias (`P1764_3`)	69,8 %	No es un dato perdido: la pregunta es de selección múltiple y el vacío significa "no la marcó". Se recodifica a sí/no.
Trabajadores pagados y socios (`P3032_1`, `_2`)	68,0 %	Vacío estructural: solo responde quien dijo que tiene ayudantes. Se rellena con 0.
Celulares inteligentes (`P978`)	42,6 %	Solo responde quien usa celular para el negocio. Se rellena con 0 y se marca.
Tenencia del local (`P3055`)	34,7 %	No aplica a quien trabaja en su vivienda o en la calle. Se crea la categoría "no aplica".

Puntos de venta y visibilidad (`P3054` , `P469`)	16,6 %	No aplica a vendedores ambulantes. Igual que el anterior.
Pidió crédito (`P1765`)	13,0 %	Pendiente revisar por qué falta. Se imputa solo con entrenamiento.

A quién representan los datos y a quién no

- **Sí representan** a los micronegocios informales (87 % sin Cámara de Comercio), que el RUES no ve.
- **Mezcla** restaurantes con hoteles y vendedores de comida: la base pública no trae el código exacto de restaurante (CIIU 5611).
- **La ganancia la declara el dueño:** no es contable y puede venir redondeada o subestimada.
- **Es una foto de 2024:** no sigue a los negocios en el tiempo, así que no sabemos cuáles cerraron.
- El total nacional del DANE excluye ocho departamentos (Amazonas, Arauca, Casanare, Guainía, Guaviare, Putumayo, Vaupés y Vichada).

04 Preparación sin fuga

> **Columnas prohibidas como pregunta del termómetro:** ventas, costos, gastos, valor agregado, ingreso mixto, sueldos, remuneración y ahorro del negocio. Todas se calculan con el dinero del negocio, que es justo la respuesta que queremos predecir. Usarlas sería como montar el tráiler con el final de la película. También excluimos el **sexo del propietario**, por razones éticas y porque la página será pública.

1. **Partición primero:** 80 % para entrenar (6.019 negocios) y 20 % de prueba (1.504), separados **por hogar** (`DIRECTORIO`) para que un mismo hogar no quede en los dos lados. Es la idea de los colegios en Saber 11. Hay 7.344 hogares para 7.523 negocios, y ningún hogar quedó compartido.
2. **Todo dentro de un Pipeline:** imputación, escalado y codificación se ajustan solo con entrenamiento, en cada pliegue.
3. **Validación cruzada estratificada y agrupada por hogar**, de 5 pliegues, con semilla 2026.
4. **El conjunto de prueba no se ha tocado.** Se usará una sola vez, con el modelo ya elegido.

05 Resultados preliminares

Línea base y cuatro modelos de tres familias del curso, con 22 variables candidatas. Promedio de 5 pliegues de validación cruzada solo sobre entrenamiento; entre paréntesis, la desviación entre pliegues.

Modelo	ROC-AUC	Exhaustividad	Precisión	F1
Línea base: decir siempre "en riesgo"	0,500	1,000	0,515	0,679
KNN, k = 51 (Lección 10)	0,757 (0,012)	0,726	0,686	0,705
Árbol de decisión, profundidad 6 (Lección 12)	0,732 (0,015)	0,637	0,688	0,658
Regresión logística	**0,774 (0,012)**	**0,741**	**0,711**	**0,725**
Random Forest, 300 árboles (Lección 13)	**0,775 (0,015)**	**0,716**	**0,714**	**0,715**

Lectura: todos los modelos le ganan claramente a la línea base y son estables entre pliegues (desviación de 0,012 a 0,015). La regresión logística y el Random Forest quedan prácticamente empatados. Si se confirma el empate, el criterio que proponemos es elegir **la logística, porque se explica mejor al dueño del restaurante**. Ojo: los hiperparámetros todavía están puestos a mano, así que estas cifras son preliminares.

Lo que más separa a los negocios en riesgo (asociación, no causa)

Pregunta	En riesgo si…	En riesgo si…
¿Dónde funciona?	vivienda: 63 %	local: 24 %
¿Cómo lleva las cuentas?	no lleva: 60 %	libro diario: 18 %
¿Tiene personas que le ayudan?	trabaja solo: 61 %	con ayudantes: 31 %
¿Acepta transferencias?	no: 59 %	sí: 34 %
¿Tiene nombre comercial?	no: 57 %	sí: 27 %
¿Está en Cámara de Comercio?	no: 56 %	sí: 20 %
¿Es visible desde la calle?	no: 73 %	sí: 44 %
¿Hace cuánto abrió?	menos de 1 año: 64 %	más de 10 años: 43 %

06 El termómetro: preguntas del formulario

La plantilla de despliegue del curso admite entre 3 y 10 variables. Esta es la propuesta inicial; la lista final saldrá de la importancia por permutación del modelo elegido.

#	Pregunta para el dueño	Columna

1	¿Dónde funciona tu negocio? (casa, local, calle, a domicilio)	`P3053`
2	¿Cómo llevas las cuentas? (no llevo, cuaderno o Excel, libro diario, contador)	`P640`
3	¿Tienes personas que te ayudan?	`P3031`
4	¿Hace cuántos meses abriste?	`P3034`
5	¿Aceptas transferencias o pagos digitales?	`P1764_3`
6	¿Tu negocio tiene nombre comercial?	`P3035`
7	¿Estás registrado en Cámara de Comercio?	`P1055`
8	¿Tu negocio se ve desde la calle?	`P469`
9	¿En qué departamento estás?	`COD_DEPTO`
10	¿Estás en una cabecera municipal o en zona rural?	`CLASE_TE`

Cómo se muestra: niveles **bajo, medio y alto**, no un porcentaje, porque un modelo puede ordenar bien sin dar porcentajes exactos. Debajo, "lo que más te está pesando", con un mensaje que conecta con LUMO. **Despliegue:** plantilla del curso (exportar el modelo a `modelo.js` y publicarlo en GitHub Pages), enlazada o incrustada en la sección del termómetro de la web de LUMO.

07 Puntos extra: dónde estamos

Bono	A favor	Falta
+5 Emprendimiento	LUMO es un producto real; la decisión y el usuario están definidos.	Anexo A (propuesta de valor, hipótesis, impacto con cifras de Passport, ruta de validación) y la sección de microcredenciales EanX. **Hay que terminar las microcredenciales.**
+5 Datos reales	Datos del DANE, hechos observados, 7.523 filas, anonimizados, suciedad real documentada.	Ficha de datos, anexo B, confirmar la licencia y las condiciones de uso del DANE.
+5 Despliegue	Ruta definida con la plantilla del curso.	Publicar el termómetro y mostrarlo funcionando el 24 de octubre.

08 Qué está hecho y qué falta

Entregable	Estado	Detalle
Anteproyecto (R10)	ACTUALIZAR	Cambiar la fuente y la pregunta, y agregar a Pedro.
Datos descargados y unidos	HECHO	8 módulos, 7.523 filas, 218 columnas.

Prueba de viabilidad	HECHO	Línea base y 4 modelos en validación cruzada (sección 05).
`ficha_datos.md` (R11)	EN CURSO	Base lista en la sección 03; falta formato final (Pedro).
`cuaderno_PFI.ipynb`	EN CURSO	Falta ajustar hiperparámetros, umbral, prueba final, equidad y exportar el modelo.
`informe_PFI.pdf` (máx. 15 págs.)	PENDIENTE	7 secciones; este avance sirve de esqueleto.
`resumen_ejecutivo_EN.pdf`	PENDIENTE	De 250 a 350 palabras (Santiago).
`declaracion_IA.md`	EN CURSO	Borradores por sesión; falta consolidar los de los dos.
Anexos A y B	PENDIENTE	A: Santiago. B: Pedro.
Repositorio GitHub (R10 a R18)	PENDIENTE	Crear `ML1_PFI_LUMO` y subir los artefactos.
Termómetro publicado	PENDIENTE	Diseño en LUMO y modelo en GitHub Pages.

Calendario hasta la entrega

Fecha	Meta
Vie 16 – Sáb 17	Feedback del profesor. Ajustar la pregunta y la fuente según su respuesta. Crear el repositorio.
Dom 18 – Lun 19	Ajustar hiperparámetros por validación cruzada, elegir el modelo con un criterio declarado, definir el umbral y abrir la prueba una sola vez.
Mar 20	Auditoría de equidad (rural/urbano, departamento, vivienda o calle). Exportar el modelo y publicar el termómetro.
Mié 21	Informe completo, anexos, resumen en inglés, declaración de IA. Revisión contra la rúbrica.
Jue 22, 11:59 p. m.	**Entrega en Canvas:** `ML1_PFI_LUMO.zip` y enlace a GitHub.
Sáb 24	**Sustentación presencial.**

09 Preguntas para el profesor

Ordenadas por importancia. Las tres primeras deciden el resto del trabajo.

1. Cambiamos la pregunta de "riesgo de cierre" (RUES) a "riesgo financiero" (EMICRON), porque el RUES solo daba 3 o 4 variables para el termómetro. ¿Es válido el cambio a esta altura, y cómo lo dejamos documentado en el informe?

Si dice que no: volvemos al RUES con menos preguntas en el termómetro.

2. ¿Los microdatos de EMICRON del DANE cuentan para el bono de datos reales, aunque sean de una encuesta y no de un registro?

Son hechos observados, anonimizados, de un portal oficial y con más de 1.000 filas.

---

3. ¿Le parece bien definir "riesgo" como "el negocio le deja al dueño menos de medio salario mínimo al mes"? ¿O conviene otro corte, como un salario mínimo completo, que deja el 79 % en riesgo?

Medio salario mínimo deja las clases casi balanceadas (51 % y 49 %).

---

4. El grupo de "alojamiento y servicios de comida" mezcla restaurantes con hoteles y vendedores ambulantes, porque la base pública no trae el CIIU exacto. ¿Basta con declararlo como límite?

---

5. ¿Debemos usar el factor de expansión (`F_EXP`) para entrenar o evaluar, o basta con mencionarlo en la ficha de datos?

---

6. ¿Está bien partir los datos por hogar (`DIRECTORIO`), como los colegios en Saber 11, aunque casi todos los hogares tengan un solo negocio?

---

7. ¿Podemos sumar las encuestas de 2022 y 2023 para tener más filas, o es mejor quedarnos solo con 2024?

---

8. Excluimos el sexo del propietario por ética. ¿Y la edad del propietario: la dejamos como variable o también la quitamos?

---

9. La logística y el Random Forest quedan casi empatados (0,774 contra 0,775 de ROC-AUC). ¿Es un criterio válido elegir la logística porque se explica mejor al usuario?

---

10. Para el despliegue, ¿basta con la plantilla del curso en GitHub Pages enlazada desde la web de LUMO, o debe estar integrada dentro de la web?

11. ¿Qué métrica de negocio espera ver? ¿Nos sirve "de cada 100 marcados como riesgo alto, cuántos lo están de verdad"?

Fuentes: DANE (2025), Encuesta de Micronegocios (EMICRON) 2024, microdatos.dane.gov.co/index.php/catalog/875, consultado el 15 de octubre de 2026; DANE, presentación de resultados EMICRON 2024; Confecámaras (2026), RUES en datos.gov.co (nb3d-v3n7). Cifras calculadas por el equipo con los microdatos descargados. Documento preparado con apoyo de Claude (Anthropic); uso declarado en la declaración de IA del proyecto.